

تجزیه و تحلیل داده کاوی - تئوری جذابی ۹۸۱۳۰۰۶ و

احمد حسینی رحیمی ۹۸۱۳۰۱۳

۱) در الگوریتم  $\text{Splitting}$ ,  $\text{Hunt}$  و  $\text{Decision Tree}$  تقسیم کارهایی انجام می‌دهد که همه فنونه‌هایی که در آن قرار می‌گیرند متعلق به یک کلاس باشند در واقع ناخالصی هدف خود را کم می‌کند.

$$a) 1 - P_1^2(\text{train-set}) - P_0^2(\text{train-set})$$

$$= 1 - 1/4 - 1/4 = 1/2$$

۳)

b) چون  $\text{ID}$ ,  $\text{nominal}$  است، می‌توان از  $\text{Multinomial Split}$  استفاده کرد.  
و  $I(\text{children})$  را برای این حساب می‌کنیم.

$$I = \sum \frac{N_{\text{child}}}{N} I_{\text{child}} = \sum_{i=1}^{20} \frac{1}{20} \times (1 - 1^2) = 0$$

c)

$$I = \frac{10}{20} \times (1 - (\frac{4}{10})^2 - (\frac{6}{10})^2) + \frac{10}{20} \times (1 - (\frac{6}{10})^2 - (\frac{4}{10})^2)$$

$$= \frac{48}{100}$$

$$d) \frac{8}{20} \times (1 - 1^2) + \frac{8}{20} \times (1 - (\frac{7}{8})^2 - (\frac{1}{8})^2) + \frac{4}{20} \times (1 - (\frac{1}{4})^2 - (\frac{3}{4})^2)$$

Sports                      luxury                      family

$$= \frac{8}{20} \times \frac{14}{16} + \frac{4}{20} \times \frac{6}{16} = \frac{52}{320} = 0.1625$$

$$e) \frac{5}{20} \times (1 - (\frac{3}{5})^2 - (\frac{2}{5})^2) + \frac{4}{20} \times (1 - 1/4 - 1/4) + \frac{4}{20} \times (1 - 1/4 - 1/4)$$

small                      large                      extra

$$+ \frac{7}{20} \times (1 - (\frac{3}{7})^2 - (\frac{4}{7})^2) = \frac{5}{20} \times \frac{12}{25} + \frac{4}{20} + \frac{7}{20} \times \frac{24}{49}$$

medium                      24/49

$$= \frac{3}{25} + \frac{4}{20} + \frac{1}{35} \approx 0.348 \dots$$

f) Car Type بهر است چون Impurity کمتری دارند و فرد ها سریع تر خاص می شوند و عموماً درست تر می شود.

g) با رسیدن آنکه  $I_{child} (ID) = 0$  چون  $overfitting$  رخ می دهد و مدل خیلی یاد نمی گیرد بلکه حفظ می کند و هیچ داده جدیدی را نمی تواند predict کند.

a)

$$Entropy = - \sum p_i \log p_i \longrightarrow I_{parent} \quad (F)$$

$$= - (P_+ \log P_+ + P_- \log P_-) = - \frac{4}{9} \log \frac{4}{9} - \frac{5}{9} \log \frac{5}{9}$$

b)

$$I(a_1) = \underbrace{\frac{4}{9} \times (-\frac{3}{4} \log \frac{3}{4} - \frac{1}{4} \log \frac{1}{4})}_{a_1 = T} + \underbrace{\frac{5}{9} \times (-\frac{4}{5} \log \frac{4}{5} - \frac{1}{5} \log \frac{1}{5})}_{a_1 = F}$$

$$I(a_2) = \underbrace{\frac{5}{9} \times (-\frac{2}{5} \log \frac{2}{5} - \frac{3}{5} \log \frac{3}{5})}_{a_2 = T} + \underbrace{\frac{4}{9} \times (-\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2})}_{a_2 = F}$$

c)  $\Delta_{info} = I_{parent} - I_{children}$

به  $I_{children}$  اصحاب می بینیم. اینها متناوب  $a_3$  را می بینیم کرده صفت:

3 instances	1 0.5	1+ 2	3- 3.5	4+ 4.5	5- 5.5	6+ 6.5	7+ 7.5	8- 8.5	6 instances
----------------	----------	---------	-----------	-----------	-----------	-----------	-----------	-----------	----------------

$X < 4.5$  ,  $X \geq 4.5$  معیار  $\Delta_{info}$  معیار برای  $\Delta_{info}$  معیار از میان برداشته می شود.

$$\Delta_{info} = I_P - I_C = \underbrace{- \frac{4}{9} \log \frac{4}{9} - \frac{5}{9} \log \frac{5}{9}}_{I_P} - \underbrace{(\frac{6}{9} \times I_{\geq 4.5} + \frac{3}{9} \times I_{< 4.5})}_{I_C}$$

که  $I_{< 4.5} = -\frac{2}{3} \log \frac{2}{3} - \frac{1}{3} \log \frac{1}{3}$  و  $I_{\geq 4.5} = -\frac{3}{6} \log \frac{3}{6} - \frac{3}{6} \log \frac{3}{6} = -1 \log \frac{1}{2}$

به طور مشابه برای حالت موارد غیر منصفانه می شود.



د) برای  $a_3$  به برای split حاصل شود، پس  $a_1$  و  $a_2$  را مقایسه می‌کنیم.  
 شود. برای  $a_1$ :

$$\Delta_{H.}(a_2) = I_{parent} - \underset{a_2=T}{\frac{5}{9} \times \left(-\frac{2}{6} \log \frac{2}{5} - \frac{3}{6} \log \frac{3}{5}\right)} - \underset{a_2=F}{\frac{4}{9} \times \left(-\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2}\right)}$$

$$\Delta(a_1) = I_{parent} - \underset{a_1=T}{\frac{4}{9} \times \left(-\frac{3}{4} \log \frac{3}{4} - \frac{1}{4} \log \frac{1}{4}\right)} - \underset{a_1=F}{\frac{5}{9} \times \left(-\frac{1}{5} \log \frac{1}{5} - \frac{4}{5} \log \frac{4}{5}\right)}$$

هر کدام که بزرگتر باشد،  $\Delta(a_1)$  و  $\Delta(a_3)$ ، برای split،  $a_3$  که در بالا یک حالت به طور کامل بحث شده، بزرگترین انتخاب می‌شود و من برای splitting خود به کار می‌رود.

e)



$$\underset{\substack{\downarrow \\ \text{on training set}}}{\text{miss}} = \frac{P_{+-} + P_{-+}}{9} = \frac{2}{9} < \text{miss} = \frac{2+2}{9} = \frac{4}{9}$$

Hence  $a_1$  is best split.

f)  $\Delta(a_1) = I_p -$

$$\Delta(a_2) = I_p - \frac{5}{9} \times \left(1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2\right) - \frac{4}{9} \times \left(1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2\right)$$

The bigger is the best split because we would obtain much purer children nodes.

(10)

a) optimistic approach  $\rightarrow err_{gen} = err_{train}$

pessimistic approach  $\rightarrow err_{gen} = err_{train} + 0.5 \times \frac{K}{N_{train}}$

$A=0, B=1$        $A=1, C=0$        $A=1, C=1$

$$err_{train} = \frac{1 + 3 + 1}{10} = \frac{1}{2}$$

$$K=4, N_{train}=10$$

$$\text{Hence optimistic} = 0.5, \text{ pessimistic} = \frac{1}{2} + \frac{1}{2} \times \frac{4}{10} = \frac{7}{10} = 0.7$$

$A=0, B=1$

$$\text{validation} = \frac{1}{5} = 0.2$$

(14) underfitting زمانی رخ می‌دهد که مدل نتواند از داده‌های موجود در train set یاد بگیرد. سبب آن می‌تواند خطای مدل روی هر دو training set و test set بسیار زیاد باشد. در این موارد مدل بسیار ساده است و به اندازه کافی complex نیست که بتواند pattern را learn کند. مدل در مدل درست تصمیم می‌گیرد اما تعداد leaf ها بسیار کوچک و نا کافی باشد.